

k-Means Algoritması ile Müşteri Segmentasyonu: RFM Analizi Yaklaşımı

Mohammed Izedin Mohammed

Öğrenci No: 255B7003

Makine Öğrenmesi Dersi - Proje (Ödev 3)

Ocak 2026

Özet: Bu projede, Online Retail II veri seti üzerinde k-Means kümeleme algoritması kullanılarak müşteri segmentasyonu gerçekleştirilmiştir. Her müşteri için RFM (Recency, Frequency, Monetary) özellikleri hesaplanmış, dağılım analizi yapılarak log dönüşümü ve standardizasyon uygulanmıştır. Elbow metodu ve Silhouette analizi ile optimal küme sayısı belirlenmiş, PCA ile 2 boyutlu görselleştirme yapılmıştır. Sonuç olarak, 5,878 müşteri 2 ana segmente ayrılmıştır. Silhouette skoru 0.4381 olarak elde edilmiştir.

I. Giriş

Müşteri segmentasyonu, pazarlama stratejilerinin etkinliğini artırmak için kritik öneme sahip bir analiz yöntemidir. Farklı müşteri gruplarının davranışlarını anlamak, işletmelerin hedefli kampanyalar oluşturmaya ve müşteri ilişkilerini güçlendirmesine olanak tanır.

RFM (Recency, Frequency, Monetary) analizi, müşteri segmentasyonunda yaygın olarak kullanılan bir yöntemdir:

- Recency (Yenilik):** Müşterinin son alışverişinden bu yana geçen süre
- Frequency (Sıklık):** Müşterinin toplam işlem sayısı
- Monetary (Parasal Değer):** Müşterinin toplam harcama tutarı

k-Means algoritması, denetimsiz öğrenme yöntemleri arasında en yaygın kullanılan kümeleme algoritmalarından biridir. Bu projede, e-ticaret verisi üzerinde RFM analizi ile k-Means kümelemesi birleştirilerek müşteri segmentasyonu gerçekleştirilmiştir.

Bu çalışmada şu sorulara yanıt aranmıştır:

- RFM özelliklerinin dağılımı nasıldır ve hangi dönüşümler gereklidir?
- Optimal küme sayısı kaçtır?
- Her kümenin karakteristik özellikleri nelerdir?

Bu raporun katkıları:

- Online Retail II veri seti için uçtan uca, tekrarlanabilir bir RFM tabanlı k-Means segmentasyon hattı.
- Skewness analizi ile gerekçelendirilmiş log dönüşümü ve standardizasyon adımlarının etkisinin ölçülmesi.

- Elbow ve Silhouette analizlerinin birlikte değerlendirilmesi ve iş açısından yorumlanabilir segmentlerin çıkarılması.

II. Veri Seti

Çalışmada UCI Machine Learning Repository'den alınan Online Retail II veri seti kullanılmıştır. Bu veri seti, İngiltere merkezli bir online perakende şirketinin 2009-2011 yılları arasındaki işlemlerini içermektedir.

Veri seti iki ayrı sayfadan oluştuğu için (2009-2010 ve 2010-2011), analiz için iki sayfa birleştirilmiş ve toplam 1,067,371 satırlık ham işlem verisi elde edilmiştir. Bu yaklaşım, zaman aralığını genişleterek müşteri davranışını daha kapsayıcı biçimde yansıtır.

Tablo 1: Veri seti özellikleri

Özellik	Değer
Toplam işlem sayısı	1,067,371
Temizlenmiş işlem sayısı	805,549
Benzersiz müşteri sayısı	5,878
Zaman aralığı	2009-2011 (2 yıl)
Kaynak	UCI Machine Learning Repository

Veri Temizleme Adımları:

- Müşteri ID'si olmayan kayıtlar çıkarıldı
- İptal edilen siparişler (Invoice 'C' ile başlayanlar) çıkarıldı
- Negatif veya sıfır miktarlı işlemler çıkarıldı
- Toplam 261,822 kayıt temizlendi

Bu adımların amacı, iade/iptal gibi gerçek satın alma davranışını temsil etmeyen kayıtların etkisini azaltmak ve RFM hesaplamalarının anlamlı müşteri davranışına dayanmasını sağlamaktır.

III. Metodoloji

A. Özellik Mühendisliği (RFM Hesaplama)


Her müşteri için aşağıdaki RFM değerleri hesaplanmıştır:

- **Recency:** Referans tarihinden (2011-12-10) müşterinin son işlem tarihine kadar geçen gün sayısı
- **Frequency:** Müşterinin yaptığı benzersiz fatura (invoice) sayısı
- **Monetary:** Müşterinin tüm işlemlerinin toplam tutarı ($\text{Quantity} \times \text{Price}$)

RFM hesaplamaları şu şekilde özetlenebilir: Recency, son işlem tarihinden referans tarihe (2011-12-10) olan gün farkıdır; Frequency, benzersiz fatura sayısıdır; Monetary ise toplam harcama tutarıdır. Referans tarihinin veri setindeki son işlem tarihinden bir gün sonrası seçilmesi, en güncel müşteriler için Recency değerinin en düşük olması gerektiği varsayımıyla uyumludur.

Tablo 2: RFM istatistikleri (orijinal değerler)

İstatistik	Recency (gün)	Frequency (sipariş)	Monetary (\$)
Ortalama	201.33	6.29	3018.62
Standart Sapma	209.34	13.01	14737.73
Minimum	1	1	2.95
%25	26	1	348.76
Medyan (%50)	96	3	898.91
%75	380	7	2307.09
Maksimum	739	398	608821.65



Şekil 1: RFM özelliklerinin orijinal dağılımları (dönüşüm öncesi)

B. Dağılım Kontrolü ve Düzenleme

1) Skewness (Çarpıklık) Analizi:

Fisher-Pearson çarpıklık katsayısı (g_1) aşağıdaki formül ile hesaplanmıştır:

$$g_1 = (1/n) \times \sum ((x_i - \mu) / \sigma)^3$$

Yorumlama: $g_1 = 0$ ise simetrik dağılım, $g_1 > 0$ ise sağa çarpık, $g_1 < 0$ ise sola çarpık.

RFM özellikleri özellikle Monetary ve Frequency için uzun kuyruklu dağılımlara sahiptir. Bu durum Öklid tabanlı algoritmalarda mesafe hesaplarını domine edebilir. Bu nedenle log-plus-one dönüşümü, büyük değerlerin etkisini azaltmak ve dağılımı daha dengeli hale getirmek için tercih edilmiştir.

Tablo 3: Skewness analizi sonuçları


Özellik	Orijinal g_1	Yorum	Log Sonrası g_1	Yorum
Recency	0.8870	Sağa çarpık	-0.4885	Yaklaşık simetrik
Frequency	12.6367	Aşırı sağa çarpık	1.0012	Hafif sağa çarpık
Monetary	25.3078	Aşırı sağa çarpık	0.2650	Yaklaşık simetrik

Önemli Bulgu: Tüm özelliklerin $g_1 > 0$ olması nedeniyle (3/3 özellik çarpık), log-plus-one dönüşümü ($y = \ln(1+x)$) uygulanmıştır. Bu dönüşüm özellikle Frequency ve Monetary özelliklerindeki aşırı çarpıklığı önemli ölçüde azaltmıştır.

2) Log Dönüşümü:

Log-plus-one dönüşümü uygulanarak özelliklerin değer aralıkları daraltılmıştır:

Özellik	Orijinal Aralık	Dönüşüm Sonrası
Recency	[1, 739]	[0.69, 6.61]
Frequency	[1, 398]	[0.69, 5.99]
Monetary	[2.95, 608821.65]	[1.37, 13.32]



Şekil 2: RFM özelliklerinin log dönüşümü sonrası dağılımları

3) Standardizasyon:

Z-score normalizasyonu uygulanarak tüm özellikler $\mu=0$, $\sigma=1$ olacak şekilde standartlaştırılmıştır:

$$z = (x - \mu) / \sigma$$

Bu proje denetimsiz öğrenme olduğundan ayrı bir eğitim/test bölmesi yapılmamış, ölçekleme parametreleri (μ ve σ) tüm veri üzerinden hesaplanmıştır. Log dönüşümü sonrası standardizasyon, RFM özelliklerini aynı ölçekte toplayarak k-Means'in mesafe tabanlı yapısına uygunluk sağlar.

C. k-Means Kümeleme

k-Means algoritması aşağıdaki parametrelerle uygulanmıştır:

- **Başlatma:** k-means++ (akıllı merkez başlatma)
- **n_init:** 10 (farklı başlangıç noktalarıyla çalıştırma)
- **max_iter:** 300
- **k aralığı:** 2-10
- **random_state:** 42 (tekrarlanabilirlik)


IV. Sonuçlar

A. Elbow Metodu Analizi

Elbow (Dirsek) metodu, farklı k değerleri için Within-Cluster Sum of Squares (WCSS/Inertia) değerlerini hesaplayarak optimal küme sayısını belirlemeye yardımcı olur. "Dirsek" noktası, WCSS'deki düşüşün yavaşladığı noktadır.

Tablo 4: Elbow analizi sonuçları

k	Inertia (WCSS)
2	8,588.81
3	6,351.98
4	4,918.64
5	4,097.83
6	3,552.98
7	3,184.84
8	2,891.60
9	2,650.60
10	2,455.91



Şekil 3: Elbow metodu ile optimal k belirleme ($k=3$ önerisi)


B. Silhouette Analizi

Silhouette skoru, kümeleme kalitesini -1 ile 1 arasında ölçer. Yüksek değerler daha iyi kümelemeyi gösterir:


- +1'e yakın: İyi kümelenmiş
- 0'a yakın: Küme sınırında
- -1'e yakın: Yanlış kümeye atanmış

Tablo 5: Silhouette analizi sonuçları

k	Silhouette Skoru	Değerlendirme
2	0.4381	En Yüksek
3	0.3478	Orta
4	0.3653	Orta
5	0.3421	Orta
6	0.3336	Orta
7	0.3052	Orta
8	0.2970	Düşük
9	0.2913	Düşük
10	0.2918	Düşük



Şekil 4: Silhouette analizi ile optimal k belirleme (k=2 önerisi)



Şekil 5: Elbow ve Silhouette analizlerinin karşılaştırması

Optimal k Seçimi: Elbow metodu k=3, Silhouette analizi k=2 önermiştir. Silhouette skorunun k=2'de en yüksek olması (0.4381) ve iş yorumlaması açısından anlamlı segmentler oluşturması nedeniyle k=2 tercih edilmiştir.

C. Küme Analizi ve Karakterizasyonu

Tablo 6: Final küme özellikleri (k=2)

Küme	Müşteri Sayısı	Oran	Recency (gün)	Frequency	Monetary (\$)	Segment Profili
0	2,352	40.0%	51.2	12.6	6,619.45	Recent, Frequent, High-value
1	3,526	60.0%	301.5	2.1	616.70	Old, Rare, Low-value


Küme Yorumlaması:

Küme 0 - VIP Müşteriler (40%):

- Ortalama 51 gün önce alışveriş yapmışlar (genel ortalama: 201 gün)
- Ortalama 12.6 sipariş vermişler (genel ortalama: 6.3)
- Ortalama \$6,619 harcamışlar (genel ortalama: \$3,019)
- **Öneri:** Öncelikli muamele, özel teklifler, sadakat programları

Küme 1 - Pasif Müşteriler (60%):

- Ortalama 302 gün önce alışveriş yapmışlar (genel ortalama: 201 gün)
- Ortalama 2.1 sipariş vermişler (genel ortalama: 6.3)
- Ortalama \$617 harcamışlar (genel ortalama: \$3,019)
- **Öneri:** Yeniden aktivasyon kampanyaları, indirim kuponları, geri kazanım stratejileri



Şekil 6: Kümelerin RFM özelliklerine göre karşılaştırması


D. PCA Görselleştirmesi

3 boyutlu RFM özellikleri, Principal Component Analysis (PCA) ile 2 boyuta indirgenmiştir:

Tablo 7: PCA açıklanan varyans oranları

Bileşen	Açıklanan Varyans	Kümülatif
PC1	76.37%	76.37%
PC2	18.77%	95.14%

İlk iki bileşen, toplam varyansın %95.14'ünü açıklamaktadır, bu da 2D görselleştirmenin orijinal verideki bilgiyi büyük ölçüde koruduğunu göstermektedir.



Şekil 7: PCA ile 2 boyutlu küme görselleştirmesi

E. Model Performansı

Tablo 8: Final model metrikleri

Metrik	Değer
Küme Sayısı (k)	2
Silhouette Skoru	0.4381
Inertia (WCSS)	8,588.81
PCA Varyans (%)	95.14%
Çalışma Süresi	~96 saniye

Silhouette skorunun $k=2$ için belirgin biçimde yüksek olması ve müşteri segmentlerinin iş açısından yorumlanabilir olması nedeniyle $k=2$ seçilmiştir. $K=3$ ve $k=4$ değerlerinde inertia azalmasına rağmen silhouette düşmekte, bu da kümelerin ayrışmasının zayıfladığını göstermektedir.

V. Tartışma

A. Dağılım Düzeltmesinin Etkisi

Orijinal RFM değerlerinin aşırı sağa çarpık olduğu gözlemlenmiştir (özellikle Monetary için $g_1=25.31$). Log dönüşümü uygulandıktan sonra çarpıklık değerleri kabul edilebilir seviyelere inmiştir. k-Means algoritması, Öklid mesafesine dayandığı için verilerin normal dağılıma yakın olması kümeleme kalitesini artırmaktadır.

B. Elbow vs Silhouette Karşılaştırması

İki yöntem farklı k değerleri önermiştir:

- Elbow ($k=3$):** WCSS düşüşünün yavaşladığı nokta
- Silhouette ($k=2$):** En yüksek kümeleme kalitesi

$k=2$ seçilmesinin nedenleri:

1. Daha yüksek Silhouette skoru (0.4381)

2. İş perspektifinden yorumlanması daha kolay segmentler
3. Pazarlama stratejileri için daha actionable içgörüler

C. Küme Karakteristikleri

Elde edilen segmentler, klasik RFM analizindeki müşteri tiplerini yansıtmaktadır. Bu segmentasyon, pazarlama ekiplerinin farklı müşteri gruplarına özel stratejiler geliştirmesine olanak tanır.

D. Sınırlılıklar

- k-Means küresel kümeler varsayar; farklı şekillerdeki kümeleri yakalayamayabilir
- Veri seti 2009-2011 dönemini kapsadığı için güncel olmayabilir
- Daha fazla küme (k=3 veya k=4) daha detaylı segmentasyon sağlayabilir
- Aykırı değerler Monetary değişkeninde güçlü etki yaratabilir
- Zaman içinde müşteri davranışları değişebileceğinden segmentler periyodik güncellenmelidir

E. Uygulama ve Tekrarlanabilirlik

Çalışma modüler bir yapıda kurgulanmış olup veri yükleme, ön işleme, kümeleme ve görselleştirme adımları ayrı dosyalar halinde düzenlenmiştir. Sonuçlar results/ klasörüne otomatik kaydedilmekte ve report.html dosyası bu çıktılarından dinamik olarak üretilmektedir. Bu yapı, farklı k değerleri veya yeni veri setleri ile tekrar çalıştırmaya uygundur.

F. Etik ve Gizlilik

Veri seti anonimleştirilmiş işlem kayıtlarından oluşmaktadır ve kişisel veri içermemektedir. Segmentasyon çıktıları, bireysel müşteri profillerini değil, toplu davranış eğilimlerini göstermektedir. Model çıktılarının kampanya tasarımında kullanılmasında ayrımcılığa yol açabilecek uygulamalardan kaçınılmalıdır.

G. Gelecek Çalışmalar

İlerleyen çalışmalarda zaman serisi etkileri, müşteri yaşam boyu değeri ve kampanya tepkileri gibi ek değişkenlerin modele dahil edilmesi planlanabilir. Ayrıca k-Means dışındaki yöntemler (DBSCAN, GMM) ile daha esnek kümeleme denemeleri yapılabilir.

VI. Sonuç

Bu projede, Online Retail II veri seti üzerinde k-Means kümeleme algoritması ile müşteri segmentasyonu başarıyla gerçekleştirilmiştir. Elde edilen sonuçlar:

- **RFM Analizi:** 5,878 müşteri için Recency, Frequency ve Monetary özellikleri hesaplanmıştır.
- **Veri Ön İşleme:** Log dönüşümü ile aşırı çarpıklık giderilmiş, standardizasyon ile özellikler normalize edilmiştir.
- **Optimal Küme Sayısı:** Silhouette analizi ile k=2 optimal olarak belirlenmiştir.
- **Silhouette Skoru:** 0.4381
- **Görselleştirme:** PCA ile %95.14 varyans korunarak 2D görselleştirme yapılmıştır.

Bu segmentasyon sonuçları, pazarlama stratejilerinin kişiselleştirilmesi, müşteri ilişkileri yönetimi ve kaynak tahsisi kararlarında kullanılabilir.

VII. Referanslar

1. J. MacQueen, "Some methods for classification and analysis of multivariate observations," Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, vol. 1, pp. 281-297, 1967.
2. P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," Journal of Computational and Applied Mathematics, vol. 20, pp. 53-65, 1987.
3. R. Tibshirani, G. Walther, and T. Hastie, "Estimating the number of clusters in a data set via the gap statistic," Journal of the Royal Statistical Society: Series B, vol. 63, no. 2, pp. 411-423, 2001.
4. D. Chen, S. L. Sain, and K. Guo, "Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining," Journal of Database Marketing & Customer Strategy Management, vol. 19, no. 3, pp. 197-208, 2012.
5. UCI Machine Learning Repository, "Online Retail II Data Set," <https://archive.ics.uci.edu/dataset/502/online+retail+ii>, 2019.
6. F. Pedregosa et al., "Scikit-learn: Machine learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.

Rapor Oluřturma Tarihi: 2026-01-15 20:29:14